Hadoop HA 集群搭建

目录

1、Hadoop HA 原理概述

为什么会有 hadoop HA 机制呢？

HA：High Available，高可用
在 Hadoop 2.0 之前,在 HDFS 集群中 NameNode 存在单点故障 (SPOF：A Single Point of Failure)。对于只有一个 NameNode 的集群，如果 NameNode 机器出现故障(比如宕机或是软件、硬件升级)，那么整个集群将无法使用，直到 NameNode 重新启动

那如何解决呢？

HDFS 的 HA 功能通过配置 Active/Standby 两个 NameNodes 实现在集群中对 NameNode 的热备来解决上述问题。如果出现故障，如机器崩溃或机器需要升级维护，这时可通过此种方式将 NameNode 很快的切换到另外一台机器。

在一个典型的 HDFS(HA) 集群中，使用两台单独的机器配置为 NameNodes 。在任何时间点，确保 NameNodes 中只有一个处于 Active 状态，其他的处在 Standby 状态。其中 ActiveNameNode 负责集群中的所有客户端操作，StandbyNameNode 仅仅充当备机，保证一旦 ActiveNameNode 出现问题能够快速切换。

为了能够实时同步 Active 和 Standby 两个 NameNode 的元数据信息（实际上 editlog），需提供一个共享存储系统，可以是 NFS、QJM（Quorum Journal Manager）或者 Zookeeper，Active Namenode 将数据写入共享存储系统，而 Standby 监听该系统，一旦发现有新数据写入，则读取这些数据，并加载到自己内存中，以保证自己内存状态与 Active NameNode 保持基本一致，如此这般，在紧急情况下 standby 便可快速切为 active namenode。为了实现快速切换，Standby 节点获取集群的最新文件块信息也是很有必要的。为了实现这一目标，DataNode 需要配置 NameNodes 的位置，并同时给他们发送文件块信息以及心跳检测。

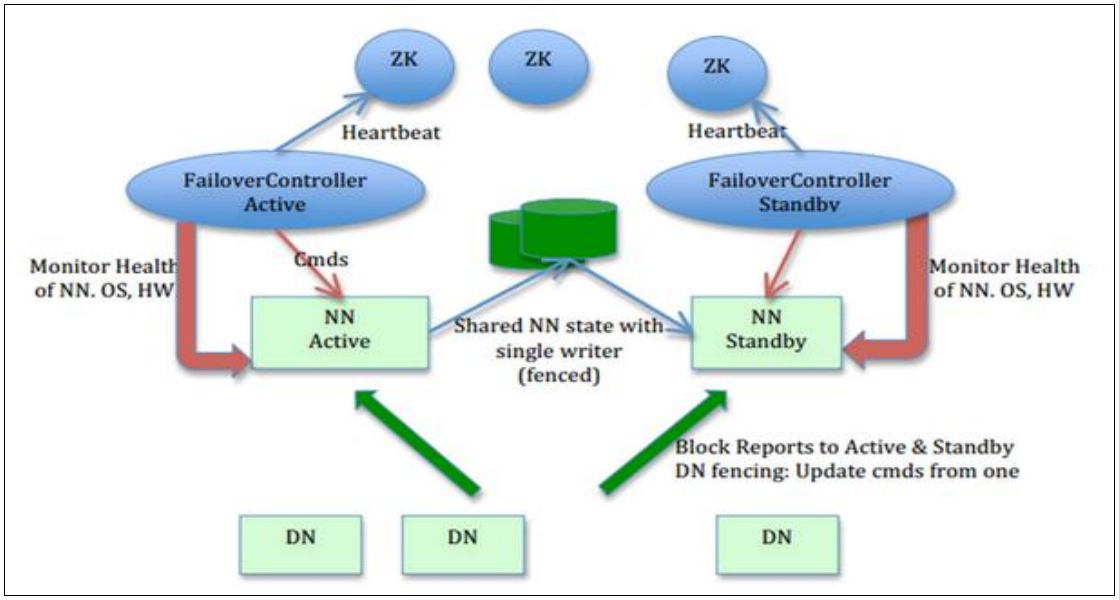

思考问题：SecondaryNameNode 和 Standby Namenode 的区别？

2、集群规划

描述：hadoop HA 集群的搭建依赖于 zookeeper，所以选取三台当做 zookeeper 集群
我总共准备了四台主机，分别是 hadoop02，hadoop03，hadoop04，hadoop05
其中 hadoop02 和 hadoop03 做 namenode 的主备切换，hadoop04 和 hadoop05 做 resourcemanager 的主备切换

四台：

	hadoop02	hadoop03	hadoop04	hadoop05
namenode	√	√		
datanode	√	√	√	√
resourcemanager			√	√
nodemanager	√	√	√	√
zookeeper	√	√	√	
journalnode	√	√	√	
zkfc	√	√		

五台：

	hadoop01	hadoop02	hadoop03	hadoop04	hadoop05
namenode	√	√			
datanode	√	√	√	√	√
resourcemanager			√	√	
nodemanager	√	√	√	√	√
zookeeper	√	√	√	√	√
journalnode		√	√	√	

zkfc	√	√			

七台：

	01	02	03	04	05	06	07
namenode	√	√					
datanode					√	√	√
resourcemanager			√	√			
nodemanager					√	√	√
zookeeper					√	√	√
journalnode					√	√	√
zkfc	√	√					

具体怎样规划，其实可以自由设置。

3、集群服务器准备

1、 修改主机名
2、 修改 IP 地址
3、 添加主机名和 IP 映射
4、 添加普通用户 hadoop 用户并配置 sudoer 权限
5、 设置系统启动级别
6、 关闭防火墙/关闭 Selinux
7、 安装 JDK
   两种准备方式：
   1、 每个节点都单独设置，这样比较麻烦。线上环境可以编写脚本实现
   2、 虚拟机环境可是在做完以上 7 步之后，就进行克隆
   3、 然后接着再给你的集群配置 SSH 免密登陆和搭建时间同步服务
8、 配置 SSH 免密登录
9、 同步服务器时间

4、集群安装

1、 安装 Zookeeper 集群
   在此略过，见 zookeeper 安装文档

2、 安装 hadoop 集群

1、 上传安装包 hadoop-2.6.5-centos-6.7.tar.gz

2、 解压到对应的安装目录
   [hadoop@hadoop02 ~]# tar -zxvf hadoop-2.6.5-centos-6.7.tar.gz -C /home/hadoop/apps/

3、 修改配置文件

1、 修改 hadoo-env.sh

修改一行

export JAVA_HOME= /usr/local/jdk1.8.0_73

2、 修改 core-site.xml

```
<configuration>
    <!-- 指定 hdfs 的 nameservice 为 myha01 -->
    <property>
        <name>fs.defaultFS</name>
        <value>hdfs://myha01/</value>
    </property>

    <!-- 指定 hadoop 工作目录 -->
    <property>
        <name>hadoop.tmp.dir</name>
        <value>/home/hadoop/data/hadoopdata/</value>
    </property>

    <!-- 指定 zookeeper 集群访问地址 -->
    <property>
        <name>ha.zookeeper.quorum</name>
        <value>hadoop02:2181,hadoop03:2181,hadoop04:2181</value>
    </property>
</configuration>
```

3、 修改 hdfs-site.xml

```
<configuration>
    <!-- 指定副本数 -->
    <property>
        <name>dfs.replication</name>
        <value>2</value>
    </property>

    <!--指定 hdfs 的 nameservice 为 myha01，需要和 core-site.xml 中保持一致-->
    <property>
        <name>dfs.nameservices</name>
        <value>myha01</value>
    </property>

    <!-- myha01 下面有两个 NameNode，分别是 nn1，nn2 -->
    <property>
        <name>dfs.ha.namenodes.myha01</name>
        <value>nn1,nn2</value>
    </property>
```

```
        <!-- nn1 的 RPC 通信地址 -->
        <property>
            <name>dfs.namenode.rpc-address.myha01.nn1</name>
            <value>hadoop02:9000</value>
        </property>

        <!-- nn1 的 http 通信地址 -->
        <property>
            <name>dfs.namenode.http-address.myha01.nn1</name>
            <value>hadoop02:50070</value>
        </property>

        <!-- nn2 的 RPC 通信地址 -->
        <property>
            <name>dfs.namenode.rpc-address.myha01.nn2</name>
            <value>hadoop03:9000</value>
        </property>

        <!-- nn2 的 http 通信地址 -->
        <property>
            <name>dfs.namenode.http-address.myha01.nn2</name>
            <value>hadoop03:50070</value>
        </property>

        <!-- 指定 NameNode 的 edits 元数据在 JournalNode 上的存放位置 -->
        <property>
            <name>dfs.namenode.shared.edits.dir</name>
<value>qjournal://hadoop02:8485;hadoop03:8485;hadoop04:8485/myha01</value>
        </property>

        <!-- 指定 JournalNode 在本地磁盘存放数据的位置 -->
        <property>
            <name>dfs.journalnode.edits.dir</name>
            <value>/home/hadoop/data/journaldata</value>
        </property>

        <!-- 开启 NameNode 失败自动切换 -->
        <property>
            <name>dfs.ha.automatic-failover.enabled</name>
            <value>true</value>
        </property>

        <!-- 配置失败自动切换实现方式 -->
```

```
        <!-- 此处配置在安装的时候切记检查不要换行-->
        <property>
            <name>dfs.client.failover.proxy.provider.myha01</name>
            <value>org.apache.hadoop.hdfs.server.namenode.ha.ConfiguredFailoverPr
    oxyProvider</value>
        </property>

        <!-- 配置隔离机制方法，多个机制用换行分割，即每个机制暂用一行-->
        <property>
            <name>dfs.ha.fencing.methods</name>
            <value>
            sshfence
            shell(/bin/true)
            </value>
        </property>

        <!-- 使用 sshfence 隔离机制时需要 ssh 免登陆 -->
        <property>
            <name>dfs.ha.fencing.ssh.private-key-files</name>
            <value>/home/hadoop/.ssh/id_rsa</value>
        </property>

        <!-- 配置 sshfence 隔离机制超时时间 -->
        <property>
            <name>dfs.ha.fencing.ssh.connect-timeout</name>
            <value>30000</value>
        </property>
    </configuration>

4、 修改 mapred-site.xml
     <configuration>
        <!-- 指定 mr 框架为 yarn 方式 -->
        <property>
            <name>mapreduce.framework.name</name>
            <value>yarn</value>
        </property>

         <!-- 设置 mapreduce 的历史服务器地址和端口号 -->
         <property>
            <name>mapreduce.jobhistory.address</name>
            <value>hadoop02:10020</value>
         </property>

         <!-- mapreduce 历史服务器的 web 访问地址 -->
```

```
        <property>
            <name>mapreduce.jobhistory.webapp.address</name>
            <value>hadoop02:19888</value>
        </property>
    </configuration>
```

5、 修改 yarn-site.xml

```
    <configuration>
    <!-- 开启 RM 高可用 -->
    <property>
        <name>yarn.resourcemanager.ha.enabled</name>
        <value>true</value>
    </property>

    <!-- 指定 RM 的 cluster id -->
    <property>
        <name>yarn.resourcemanager.cluster-id</name>
        <value>yrc</value>
    </property>

    <!-- 指定 RM 的名字 -->
    <property>
        <name>yarn.resourcemanager.ha.rm-ids</name>
        <value>rm1,rm2</value>
    </property>

    <!-- 分别指定 RM 的地址 -->
    <property>
        <name>yarn.resourcemanager.hostname.rm1</name>
        <value>hadoop04</value>
    </property>

    <property>
        <name>yarn.resourcemanager.hostname.rm2</name>
        <value>hadoop05</value>
    </property>

    <!-- 指定 zk 集群地址 -->
    <property>
        <name>yarn.resourcemanager.zk-address</name>
        <value>hadoop02:2181,hadoop03:2181,hadoop04:2181</value>
    </property>

    <!-- 要运行 MapReduce 程序必须配置的附属服务 -->
```

```
        <property>
            <name>yarn.nodemanager.aux-services</name>
            <value>mapreduce_shuffle</value>
        </property>

        <!-- 开启 YARN 集群的日志聚合功能 -->
        <property>
            <name>yarn.log-aggregation-enable</name>
            <value>true</value>
        </property>

        <!-- YARN 集群的聚合日志最长保留时长 -->
        <property>
            <name>yarn.log-aggregation.retain-seconds</name>
            <value>86400</value>
        </property>

        <!-- 启用自动恢复 -->
        <property>
            <name>yarn.resourcemanager.recovery.enabled</name>
            <value>true</value>
        </property>

        <!-- 制定 resourcemanager 的状态信息存储在 zookeeper 集群上-->
        <property>
            <name>yarn.resourcemanager.store.class</name>
            <value>org.apache.hadoop.yarn.server.resourcemanager.recovery.ZKRMStateSt
ore</value>
        </property>
        </configuration>
```

6、 修改 slaves

vi slaves

添加 datanode 的节点地址：

```
hadoop02
hadoop03
hadoop04
hadoop05
```

7、 分发安装包到其他机器

```
scp -r hadoop-2.6.5 hadoop@hadoop03:$PWD
scp -r hadoop-2.6.5 hadoop@hadoop04:$PWD
scp -r hadoop-2.6.5 hadoop@hadoop05:$PWD
```

8、 并分别配置环境变量

vi ~/.bashrc

添加两行：

export HADOOP_HOME=/home/hadoop/apps/hadoop-2.6.5

export PATH=$PATH:$HADOOP_HOME/bin:$HADOOP_HOME/sbin

保存退出

4、 集群初始化操作（**记住：严格按照以下步骤执行**）

1、 先启动 zookeeper 集群

启动：**zkServer.sh start**

检查启动是否正常：zkServer.sh status

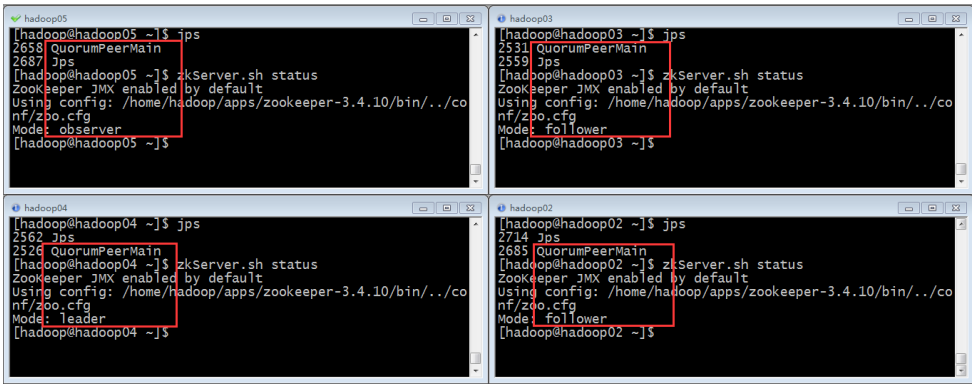

2、 分别在每个 zookeeper（也就是规划的三个 journalnode 节点，不一定跟 zookeeper 节点一样）节点上启动 journalnode 进程

[hadoop@hadoop02 ~]$ hadoop-daemon.sh start journalnode

[hadoop@hadoop03 ~]$ hadoop-daemon.sh start journalnode

[hadoop@hadoop04 ~]$ hadoop-daemon.sh start journalnode

然后用 jps 命令查看是否各个 datanode 节点上都启动了 journalnode 进程

如果报错，根据错误提示改进

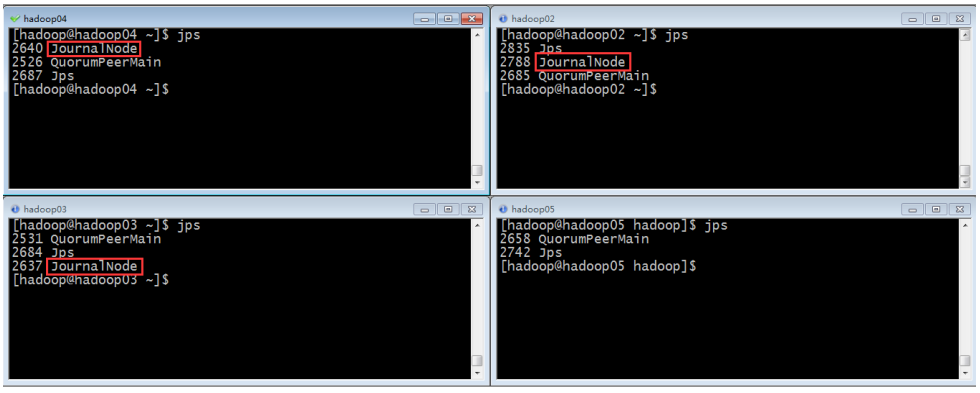

3、 在第一个 namenode 上执行格式化操作

[hadoop@hadoop02 ~]$ hadoop namenode -format

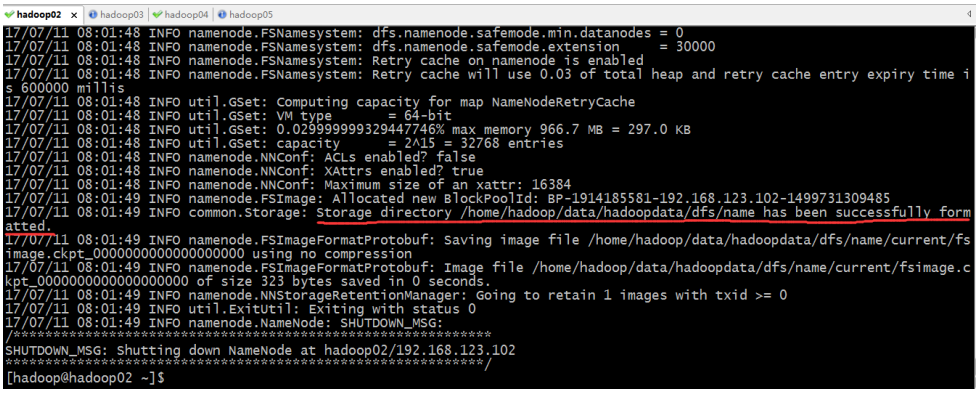

然后会在 core-site.xml 中配置的临时目录中生成一些集群的信息

把他拷贝的第二个 namenode 的相同目录下

<name>hadoop.tmp.dir</name>

<value>/home/hadoop/data/hadoopdata/</value>

这个目录下，千万记住：两个 namenode 节点该目录中的数据结构是一致的

[hadoop@hadoop02 ~]$ scp -r ~/data/hadoopdata/ hadoop03:~/data

或者也可以在另一个 namenode 上执行：hadoop namenode -bootstrapStandby

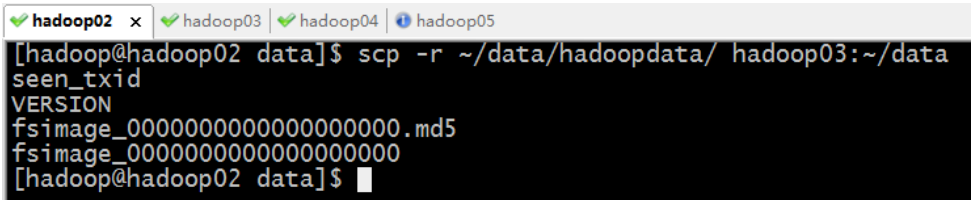

4、 格式化 ZKFC

[hadoop@hadoop02 ~]$ hdfs zkfc -formatZK

在第一台机器上即可

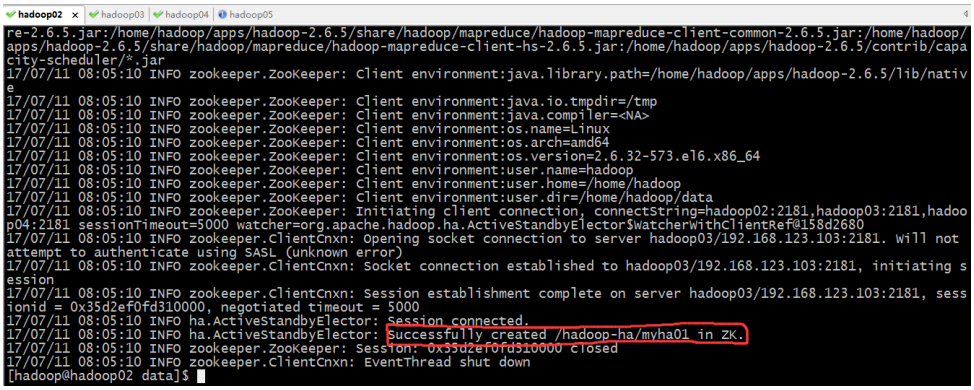

5、 启动 HDFS

[hadoop@hadoop02 ~]$ start-dfs.sh

```
[hadoop@hadoop02 data]$ start-dfs.sh
Starting namenodes on [hadoop02 hadoop03]
hadoop03: starting namenode, logging to /home/hadoop/apps/hadoop-2.6.5/logs/hadoop-hadoop-namenode-hadoop03.out
hadoop02: starting namenode, logging to /home/hadoop/apps/hadoop-2.6.5/logs/hadoop-hadoop-namenode-hadoop02.out
hadoop04: starting datanode, logging to /home/hadoop/apps/hadoop-2.6.5/logs/hadoop-hadoop-datanode-hadoop04.out
hadoop05: starting datanode, logging to /home/hadoop/apps/hadoop-2.6.5/logs/hadoop-hadoop-datanode-hadoop05.out
hadoop03: starting datanode, logging to /home/hadoop/apps/hadoop-2.6.5/logs/hadoop-hadoop-datanode-hadoop03.out
hadoop02: starting datanode, logging to /home/hadoop/apps/hadoop-2.6.5/logs/hadoop-hadoop-datanode-hadoop02.out
Starting journal nodes [hadoop02 hadoop03 hadoop04]
hadoop04: journalnode running as process 2640. Stop it first.
hadoop03: journalnode running as process 2637. Stop it first.
hadoop02: journalnode running as process 2788. Stop it first.
Starting ZK Failover Controllers on NN hosts [hadoop02 hadoop03]
hadoop03: starting zkfc, logging to /home/hadoop/apps/hadoop-2.6.5/logs/hadoop-hadoop-zkfc-hadoop03.out
hadoop02: starting zkfc, logging to /home/hadoop/apps/hadoop-2.6.5/logs/hadoop-hadoop-zkfc-hadoop02.out
[hadoop@hadoop02 data]$
```

查看各节点进程是否启动正常：依次为 2345 四台机器的进程

```
hadoop02
[hadoop@hadoop02 data]$ jps
3520 DFSZKFailoverController
3587 Jps
2788 JournalNode
3237 DataNode
2685 QuorumPeerMain
3103 NameNode
[hadoop@hadoop02 data]$
```

```
hadoop04
[hadoop@hadoop04 ~]$ jps
2640 JournalNode
2837 Jps
2742 DataNode
2526 QuorumPeerMain
[hadoop@hadoop04 ~]$
```

```
hadoop03
[hadoop@hadoop03 ~]$ jps
2784 NameNode
2531 QuorumPeerMain
3075 Jps
3019 DFSZKFailoverController
2637 JournalNode
2862 DataNode
[hadoop@hadoop03 ~]$
```

```
hadoop05
[hadoop@hadoop05 hadoop]$ jps
2658 QuorumPeerMain
2867 Jps
2796 DataNode
[hadoop@hadoop05 hadoop]$
```

访问 web 页面 http://hadoop02:50070

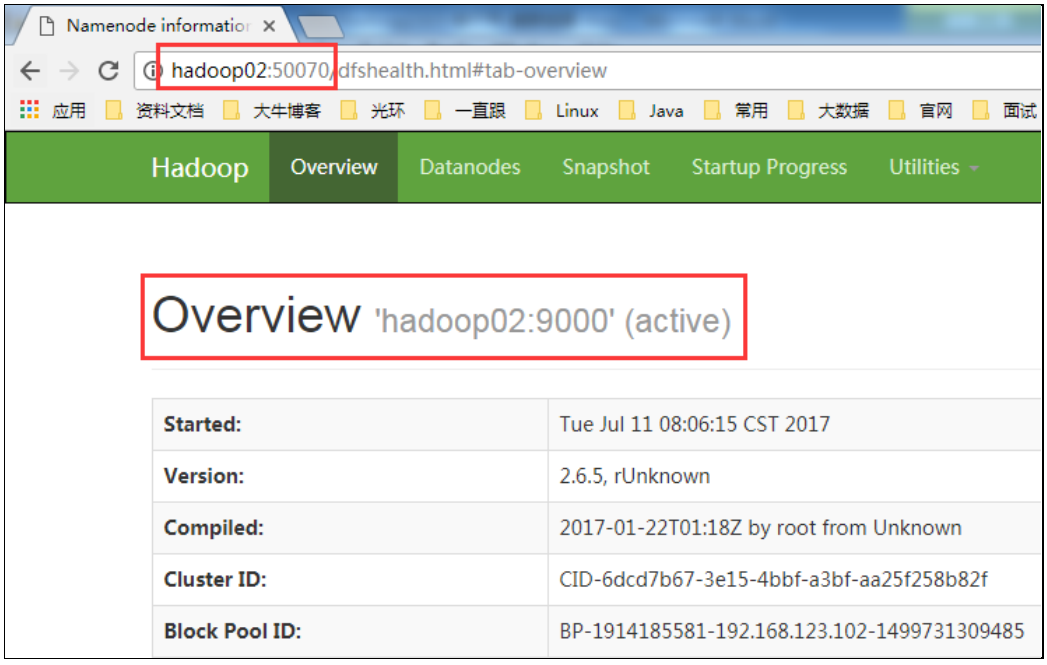

访问 web 页面：http://hadoop03:50070

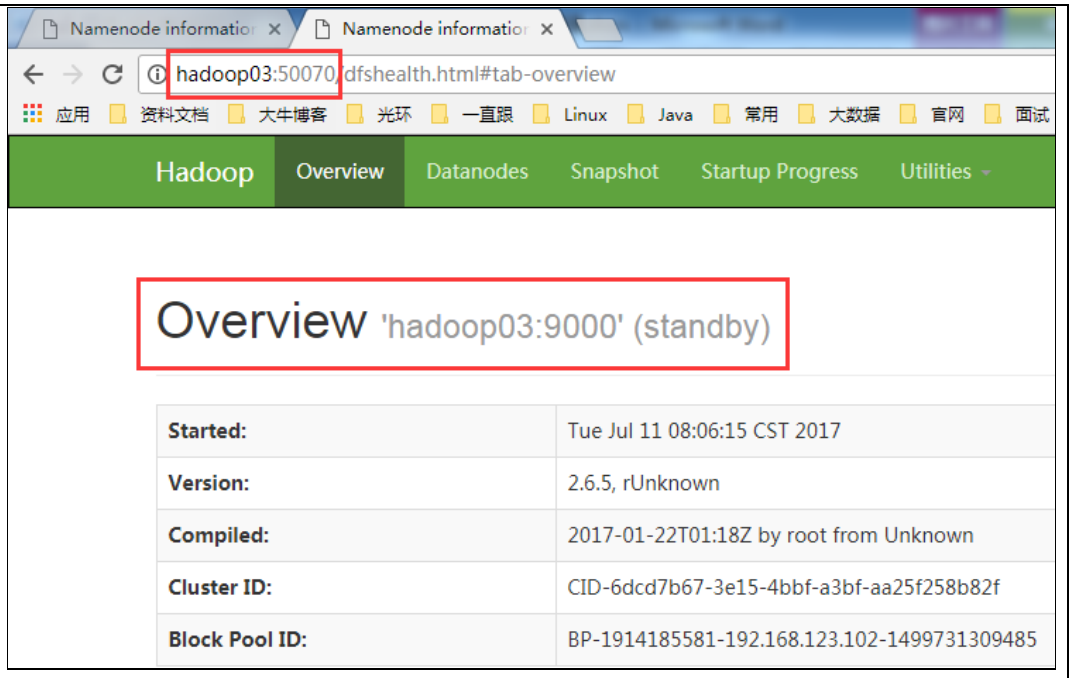

6、 启动 YARN

[hadoop@hadoop04 ~]$ start-yarn.sh

在主备 resourcemanager 中随便选择一台进行启动，正常启动之后，检查各节点的进程：

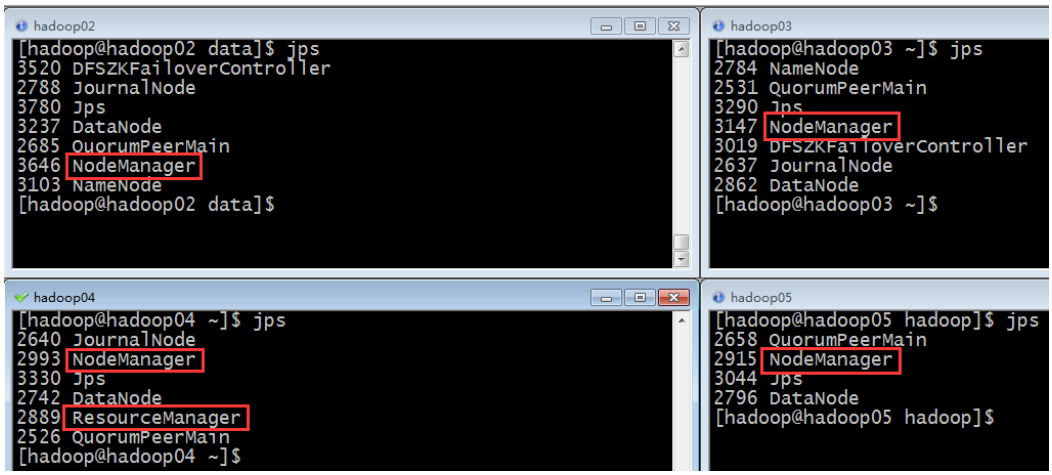

若备用节点的 resourcemanager 没有启动起来，则手动启动起来

[hadoop@hadoop04 ~]$ yarn-daemon.sh start resourcemanager

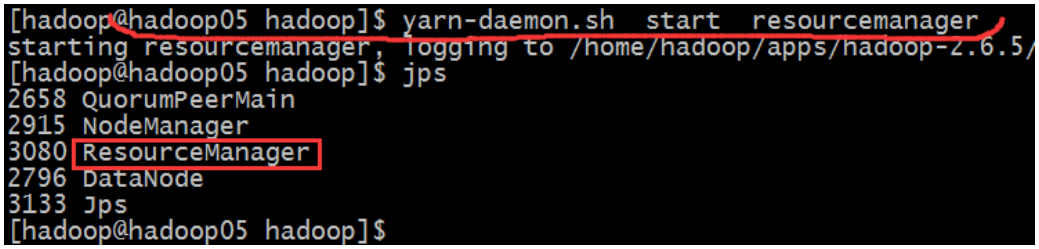

之后打开浏览器访问页面：http://hadoop04:8088

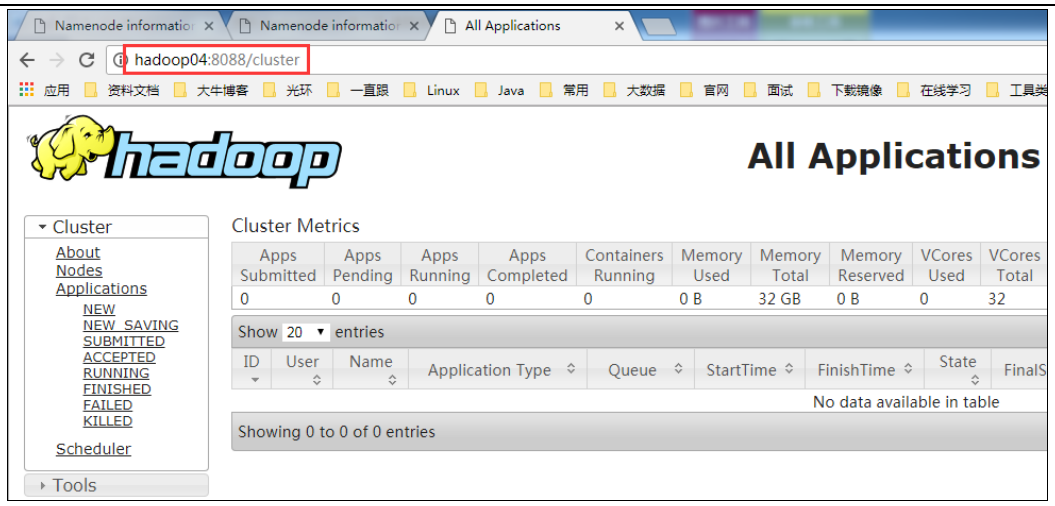

访问 web 页面：http://hadoop05:8088

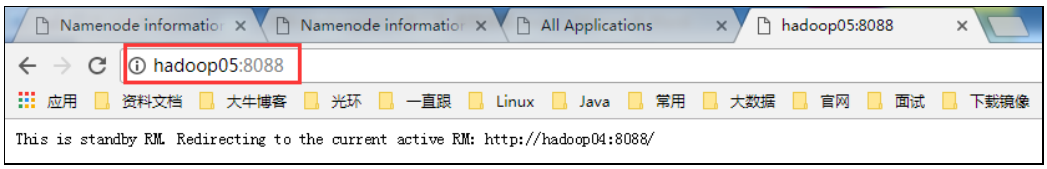

hadoop05 是 standby resourcemanager，会自动跳转到 hadoop04

7、 查看各主节点的状态

HDFS:

hdfs haadmin -getServiceState nn1

hdfs haadmin -getServiceState nn2

```
[hadoop@hadoop04 mapreduce]$ hdfs haadmin -getServiceState nn1
standby
[hadoop@hadoop04 mapreduce]$ hdfs haadmin -getServiceState nn2
active
```

YARN:

yarn rmadmin -getServiceState rm1

yarn rmadmin -getServiceState rm2

```
[hadoop@hadoop04 mapreduce]$ yarn rmadmin -getServiceState rm1
active
[hadoop@hadoop04 mapreduce]$ yarn rmadmin -getServiceState rm2
standby
```

8、 启动 mapreduce 任务历史服务器

[hadoop@hadoop02 ~]$ mr-jobhistory-daemon.sh start historyserver

按照配置文件配置的历史服务器的 web 访问地址去访问：

http://hadoop02:19888

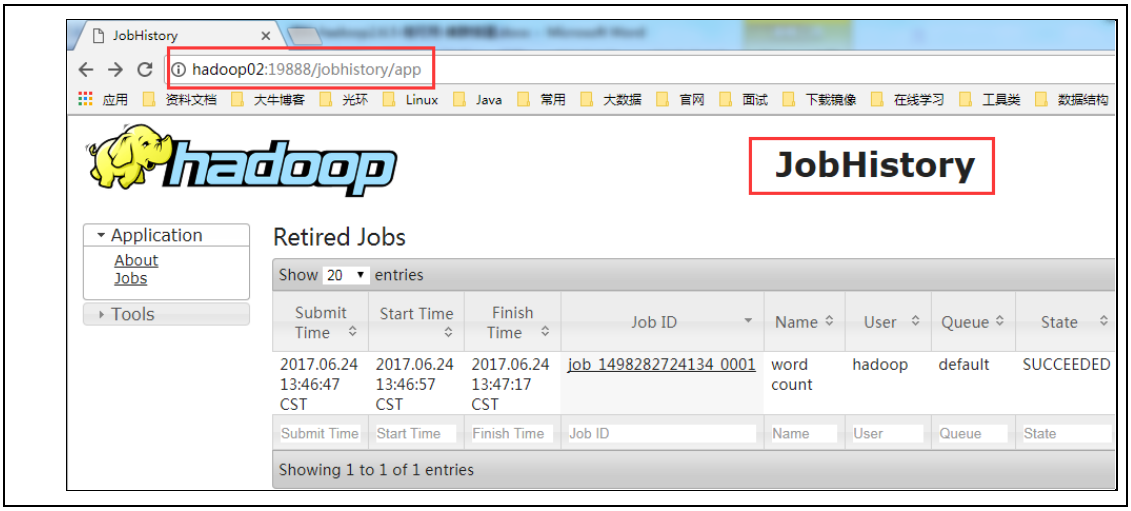

5、集群启动测试

1、干掉 active namenode， 看看集群有什么变化
2、在上传文件的时候干掉 active namenode， 看看有什么变化
3、干掉 active resourcemanager， 看看集群有什么变化
4、在执行任务的时候干掉 active resourcemanager，看看集群有什么变化